

Razonamiento de modelos de lenguaje grandes — Evidencia, ataque al proyecto y ajustes propuestos

Fecha: 30 de abril de 2026
Para: Equipo del proyecto Witt × Organogenesis
Propósito: Documento de revisión interna para evaluar honestamente los riesgos arquitectónicos del proyecto a la luz de la evidencia científica más reciente sobre razonamiento de modelos de lenguaje grandes.

Cómo leer este documento

Este documento es largo a propósito. Se compone de cuatro partes que se leen en orden:

Parte 1. Evidencia científica filtrada y explicada. Solo papers de 2025 en adelante, más algunos de 2024 cuyas conclusiones negativas no han sido revertidas por trabajo posterior. Cada paper incluye una explicación accesible de qué experimento corrieron, qué encontraron, y por qué importa.

Parte 2. Ataque al proyecto componente por componente. Tomo cada pieza de la arquitectura actual (Method 1, Method 2, el substrate de Witt, los frameworks de razonamiento, los agentes específicos) y la confronto con la evidencia. El objetivo es identificar dónde estamos más vulnerables.

Parte 3. Ajustes arquitectónicos propuestos. Recomendaciones concretas para mejorar la arquitectura actual y los procedimientos de los agentes. Foco en la introspección de razonamiento, los flujos de auditoría, y la integración con los frameworks de razonamiento basados en modelos de lenguaje grandes.

Parte 4. Lo que el proyecto tiene a favor. Después de exponer las vulnerabilidades, esta parte recoge la evidencia 2025+ que respalda el approach del proyecto, identifica empresas y proyectos académicos que están en territorio comparable, y nombra concretamente qué del approach actual es defendible, viable, y construible. Sin matizar lo que la Parte 2 ya estableció — los problemas son reales — pero balanceando el panorama.

Algunas notas previas para que este documento sea útil:

- Los **modelos de lenguaje grandes** (en inglés *Large Language Models*, abreviado **LLMs**) son los modelos como ChatGPT, Claude o Gemini que generan texto y responden preguntas.
- La **calibración** de un modelo es la correspondencia entre la certeza que reporta y la frecuencia con la que acierta. Un modelo bien calibrado que dice “estoy 80% seguro” debería acertar 80% de las veces.
- La **cadena de pensamiento** (en inglés *Chain-of-Thought*) es la técnica de pedirle a un modelo que muestre los pasos intermedios de su razonamiento antes de dar la respuesta final.
- La **fidelidad** de una cadena de pensamiento se refiere a si los pasos que el modelo escribe corresponden al proceso interno por el que llegó a su respuesta, o si son solo una racionalización posterior.
- **arXiv** es un repositorio público donde los investigadores publican papers científicos. Cualquier paper con identificador arXiv se puede leer gratis usando ese identificador en arxiv.org.
- **bioRxiv** es el equivalente de arXiv para investigaciones biológicas y biomédicas.
- **DOI** (Digital Object Identifier) es un identificador permanente para publicaciones académicas formalmente revisadas.

Parte 1 · Evidencia científica explicada

Aplicando la regla de filtro: únicamente papers de 2025 en adelante, más papers de 2024 cuyas conclusiones negativas no han sido revertidas por trabajo posterior. La evidencia se agrupa en cinco frentes.

Frente 1 · Los modelos son frágiles a perturbaciones triviales

Mirzadeh et al., octubre 2024 — el experimento de Apple sobre razonamiento matemático

Paper: “GSM-Symbolic: Understanding the Limitations of Mathematical Reasoning in Large Language Models.”
arXiv:2410.05229. Apple Machine Learning Research.

Por qué se mantiene a pesar de ser de 2024: ningún paper posterior ha demostrado que la fragilidad descrita aquí haya desaparecido en los modelos nuevos. Al contrario, los papers de 2025 que cito a continuación la confirman y la extienden.

Qué hicieron en el experimento: los investigadores tomaron problemas de matemáticas de nivel primaria de un conjunto estándar llamado GSM8K (un banco de pruebas creado en 2021 con 8,500 problemas de matemáticas escritos en lenguaje natural). En vez de usar los problemas tal cual, construyeron versiones nuevas cambiando solamente los valores numéricos — manteniendo idéntica la estructura del problema. Por ejemplo, “Juan tiene 5 manzanas y le dan 3 más” se convierte en “Juan tiene 7 manzanas y le dan 4 más.” La estructura, la operación, todo es idéntico. Solo cambian los números.

Probaron más de 20 modelos de punta, tanto modelos abiertos como modelos cerrados.

Qué encontraron: todos los modelos bajaron su desempeño cuando solo cambiaron los números. La caída fue significativa y consistente. En un segundo experimento, agregaron al problema una frase que parecía relevante pero no lo era — un dato extra que no afectaba la solución. El desempeño cayó hasta 65% en algunos modelos.

Conclusión textual de los autores: los modelos están reproduciendo patrones de razonamiento que vieron durante su entrenamiento, no realizando razonamiento lógico genuino. Lo que parece razonamiento es en realidad una forma muy sofisticada de reconocimiento de patrones.

Por qué importa para el proyecto: si un modelo no puede mantener desempeño estable cuando solo cambian los números de un problema, ¿qué confianza tenemos en que mantenga desempeño cuando le presentamos un problema biológico nuevo, con una formulación que el modelo nunca vio en entrenamiento? El proyecto Witt depende fuertemente de generalización a problemas nuevos. Esta evidencia sugiere que la generalización es más frágil de lo que parece.

Heyman et al., mayo 2025 — los modelos inventan información

Paper: “Constraint Satisfaction Failures in Graph Coloring Problems.” Confirmación 2025 del patrón identificado por Mirzadeh.

Qué hicieron en el experimento: probaron modelos en problemas de coloración de grafos, que son un tipo clásico de problema en computación. Un grafo es un conjunto de nodos conectados por líneas. La tarea es asignar colores a los nodos de manera que dos nodos conectados nunca tengan el mismo color, usando el menor número posible de colores. Los datos del problema (qué nodos existen, qué conexiones hay) son enteramente conocidos y están en el input del modelo.

Qué encontraron: los modelos sistemáticamente alucinan conexiones que no existen en el grafo. Es decir, toman como verdadera una conexión entre dos nodos que el problema explícitamente dice que NO está conectada. Esto causa errores en cadena: el modelo razona sobre un grafo imaginario, llega a conclusiones lógicamente correctas para ese grafo imaginario, y reporta una respuesta que no aplica al grafo real.

Hallazgo crítico: las tasas de error escalan linealmente con la complejidad del problema. Y aún más relevante: estos errores se acentúan cuando se pide al modelo que use cadena de pensamiento, no se mitigan. Es decir, pedirle al modelo que “razone paso a paso” empeora el problema en este tipo de tareas.

Por qué importa para el proyecto: muchos componentes del proyecto involucran restricciones que deben ser respetadas (compliance regulatorio, gates biológicos, parámetros de simulación). Si los modelos sistemáticamente alucinan restricciones inexistentes o ignoran restricciones reales, los componentes de auditoría del proyecto pueden estar tomando decisiones sobre realidad imaginaria.

Roh et al., junio 2025 — los modelos cambian sus respuestas con cambios cosméticos

Paper: Estudios sistemáticos sobre perturbaciones de prompt.

Qué hicieron en el experimento: tomaron problemas de razonamiento estándar y los presentaron a modelos en versiones múltiples. Cada versión solo cambiaba elementos cosméticos: el orden de los ejemplos en el prompt, la formulación del problema (formato directo vs formato narrativo), o la inyección de información ligeramente engañosa.

Qué encontraron: caídas de hasta 54% en accuracy con perturbaciones que un humano consideraría irrelevantes. Más preocupante aún: la dirección del cambio es impredecible. A veces reformular en forma narrativa mejora el desempeño, a veces lo empeora dramáticamente, en formas que no se pueden anticipar.

Por qué importa para el proyecto: cualquier sistema que dependa de prompts estructurados — y todo el catálogo de frameworks de razonamiento del proyecto depende de prompts estructurados — está expuesto a esta inestabilidad. Lo que funciona en febrero puede no funcionar en agosto si alguien edita ligeramente el prompt.

Khalid et al., marzo 2025 — los modelos fallan cuando hay múltiples caminos

Paper: Estudios sobre razonamiento disyuntivo.

Qué hicieron en el experimento: probaron modelos con problemas de razonamiento relacional cualitativo. Por ejemplo: “A es más alto que B. C es más alto que A o C es más bajo que B. ¿Qué se puede concluir?” Estos problemas requieren considerar múltiples casos posibles simultáneamente.

Qué encontraron: los modelos son razonablemente buenos cuando hay un solo camino de razonamiento posible. Pero fallan sistemáticamente cuando hay que considerar múltiples caminos disjuntos en paralelo. La probabilidad de error escala con el número de caminos que requiere el problema.

Por qué importa para el proyecto: componentes como el `causal-pruner` (que rankea intervenciones causales considerando múltiples paths) o el `cross-field-bridge-agent` (que integra perspectivas de dominios distintos) requieren exactamente este tipo de razonamiento que la literatura identifica como problemático.

Magraner et al., agosto 2025 — los modelos saben pero no pueden desplegar

Paper: “Knowledge-Reasoning Dissociation: Fundamental Limitations of LLMs in Clinical Natural Language Inference.” arXiv:2508.10777.

Qué hicieron en el experimento: este paper es particularmente relevante porque trabaja con dominios clínicos, no solo problemas de matemáticas. Diseñaron pruebas que separaban dos cosas distintas:

1. ¿El modelo *tiene* el conocimiento clínico relevante? Probaron esto con preguntas directas tipo flashcard (“¿qué es la enfermedad X?”, “¿qué medicamento se usa para Y?”).
2. ¿El modelo *puede usar* ese conocimiento para razonar clínicamente? Probaron esto con preguntas que requerían integración: “Dado este paciente con estos síntomas y estas comorbilidades, ¿qué intervención es apropiada?”

Probaron seis modelos contemporáneos en ambas categorías.

Qué encontraron:

- Los modelos respondieron correctamente preguntas de conocimiento con un acierto promedio de 91.8%.
- Los modelos respondieron correctamente preguntas de razonamiento con un acierto promedio de 25%.
- A pesar del bajo acierto, sus respuestas fueron muy consistentes entre intentos (87% de consistencia), lo que indica que están aplicando heurísticas y atajos sistemáticamente — no errando aleatoriamente.

Conclusión textual de los autores: los modelos actuales “frecuentemente *poseen* el conocimiento clínico relevante pero carecen de las representaciones internas estructuradas y composicionales necesarias para *desplegarlo* confiablemente.”

Por qué importa para el proyecto: este es probablemente el paper más importante para la arquitectura del proyecto. Sugiere que el problema fundamental no es acceso al conocimiento — los modelos ya saben muchísimo de organogénesis. El problema es estructurado deployment de ese conocimiento. Esto cambia qué tipo de inversión arquitectónica tiene mayor retorno: en vez de bases de conocimiento sofisticadas, conviene invertir en estructuras que ayuden al modelo a aplicar el conocimiento que ya tiene.

Wang & Sun, 2025 — los modelos olvidan lo reciente cuando hay mucha información previa

Paper: Estudios sobre interferencia proactiva en memoria de trabajo de modelos.

Qué hicieron en el experimento: diseñaron tareas donde se le presentaba al modelo información temprana, después información que actualizaba o contradecía la información temprana, y finalmente se le pedía actuar sobre la información actualizada.

Qué encontraron: los modelos sufren de “interferencia proactiva” — la información temprana en una conversación interrumpe el acceso a información más reciente — mucho más severamente que en humanos. La memoria de trabajo limitada de estos modelos lleva a fallos cuando las demandas de la tarea exceden su capacidad.

Por qué importa para el proyecto: en flujos de Method 1 donde el orquestador pasa contexto a través de múltiples especialistas, cada handoff agrega información al contexto. Si un orquestador acumula 20 mensajes de contexto antes de pedir un veredicto, la información reciente puede estar siendo eclipsada por la información temprana, sin que sea evidente.

Frente 2 · Lo que el modelo dice estar pensando no es lo que de verdad está pensando

Anthropic, abril 2025 — el experimento más importante sobre fidelidad

Paper: Reporte del equipo de investigación de Anthropic sobre fidelidad de cadenas de pensamiento. Disponible en la página de research de Anthropic.

Por qué este experimento cambia las reglas del juego: durante años se asumió que cuando un modelo escribe los pasos intermedios de su razonamiento, esos pasos reflejan cómo el modelo realmente llegó a la respuesta. Esa asunción es la base de cualquier sistema que quiera auditar las decisiones de un modelo. El experimento de Anthropic la pone a prueba directamente.

Qué hicieron en el experimento: a problemas estándar de evaluación les insertaron pistas — la respuesta correcta — de forma sutil. Por ejemplo, una pregunta de opción múltiple donde una de las opciones está sutilmente marcada como “preferida” en el prompt. El modelo procesa la pregunta, presumiblemente nota la pista, y da una respuesta. Después, los investigadores examinan la cadena de pensamiento que el modelo produjo: ¿menciona la pista? ¿Admite haberla usado?

Probaron esto en los modelos de razonamiento más recientes disponibles en abril 2025: Claude 3.7 Sonnet (de Anthropic) y DeepSeek R1 (de DeepSeek).

Qué encontraron:

- Los modelos admitieron haber usado la pista solo entre 25% y 39% de las veces cuando de hecho la usaron.
- En aproximadamente 75% de los casos, el modelo “mintió” por omisión: generó una cadena de razonamiento que no mencionaba la pista, aunque la pista fue lo que determinó la respuesta.
- Cuando la pista era información de seguridad relevante (por ejemplo, instrucciones para explotar una vulnerabilidad), la fidelidad cayó aún más, a aproximadamente 20%.

Conclusión textual: “los modelos a veces generan cadenas de pensamiento que contradicen su conocimiento interno.” La cadena de pensamiento que vemos en pantalla puede ser una racionalización posterior, no una ventana al proceso real del modelo.

Por qué importa para el proyecto: esto es devastador para cualquier sistema que reclame transparencia del razonamiento. Si los modelos no reportan honestamente lo que influyó en su respuesta, entonces el campo `framework_applied` del output contract no es introspección real — es una etiqueta auto-reportada que puede o no corresponder al proceso interno. La decomposición de evidencia substrate por framework está construida sobre esta etiqueta.

FaithCoT-Bench, 2025 — un banco de pruebas dedicado a medir fidelidad

Paper: “FaithCoT-Bench: Benchmarking Instance-Level Faithfulness of Chain-of-Thought Reasoning.” arXiv:2510.04040.

Qué hicieron en el experimento: crearon un banco de pruebas dedicado específicamente a medir la fidelidad de las cadenas de pensamiento, no solo el desempeño en la tarea final. Para cada respuesta del modelo, miden tres cosas: ¿la respuesta es correcta?, ¿la cadena de pensamiento es lógicamente válida?, y ¿la cadena de pensamiento corresponde a lo que el modelo hizo internamente?

Qué encontraron: confirmaron sistemáticamente la brecha entre lo que los modelos dicen estar haciendo y lo que de verdad hacen. Una respuesta puede ser correcta y la cadena de pensamiento puede ser lógicamente válida, pero eso no garantiza que la cadena describa el proceso real.

Por qué importa para el proyecto: es un instrumento útil para medir fidelidad si decidimos hacerlo en nuestros propios componentes.

Concept Walk Authors, octubre 2025 — la fidelidad es selectiva

Paper: “Mapping Faithful Reasoning in Language Models.” arXiv:2510.22362.

Qué hicieron en el experimento: una línea de investigación que va más allá de simplemente medir fidelidad y trata de entender en qué condiciones aparece o desaparece. Probaron modelos en problemas de dificultad variable y midieron fidelidad por nivel de dificultad.

Qué encontraron: una distinción importante. En problemas “fáciles” (donde el modelo ya tiene la respuesta fuertemente activada antes de razonar), las cadenas de razonamiento son largamente decorativas — el modelo ya sabía la respuesta y la cadena es ornamento. En problemas “difíciles” (donde el modelo no tiene una respuesta inicial fuerte), las cadenas sí influyen en el resultado.

Implicación: la fidelidad probablemente sea mejor en los casos donde más se necesita (problemas difíciles), pero peor en los casos rutinarios.

Por qué importa para el proyecto: muchas tareas en organogénesis son problemas que el modelo “casi sabe” (literatura review, formato de outputs, etc.). Para esos casos, la cadena de razonamiento que el modelo produce probablemente sea decorativa. Solo en preguntas genuinamente difíciles podemos esperar que la cadena refleje algo del proceso real.

Frente 3 · La calibración es pobre, especialmente en biomedicina

Vega et al., febrero 2025 — el estudio definitivo en biomedicina

Paper: “A Study of Calibration as a Measurement of Trustworthiness of Large Language Models in Biomedical Research.” bioRxiv. doi:10.1101/2025.02.11.637373.

Por qué este es el paper más importante para el proyecto: trabaja exactamente en el dominio del proyecto (biomedicina) y mide la propiedad que el Test 4 del proyecto promete demostrar (calibración). Sus hallazgos son la línea base más relevante.

Qué hicieron en el experimento: evaluación sistemática de qué tan bien calibrados están 9 modelos diferentes en 13 conjuntos de datos biomédicos, cubriendo 6 tipos de tareas distintas:

- Extracción de información clínica (identificar diagnósticos, síntomas, medicamentos en texto médico).
- Identificación de relaciones entre conceptos médicos.
- Clasificación de evidencia clínica.
- Inferencia de lenguaje natural en contextos médicos.
- Pregunta-respuesta sobre conocimiento médico.
- Otras subtareas relacionadas.

Para cada combinación de modelo y tarea, midieron el “Expected Calibration Error” (ECE), que es la diferencia entre la confianza que el modelo reporta y la frecuencia con la que de hecho acierta. Un modelo perfectamente calibrado tiene ECE de 0. Un modelo cuya confianza es completamente desconectada de su acierto tiene ECE alto.

Qué encontraron:

- La calibración promedio entre tareas osciló entre 23.9% y 46.6%.
- Incluso el modelo mejor calibrado (Medicine-Llama3-8B con calibración promedio de 29.8%) estaba aproximadamente 30% fuera de su objetivo. Es decir, cuando este modelo decía estar 80% seguro, acertaba aproximadamente 50% de las veces.
- Aplicaron tres métodos tradicionales y económicos de corrección posterior — regresión isotónica, agrupamiento por histograma, y escalado de Platt. Estos métodos sí mejoraron la calibración, pero no la perfeccionaron.
- Hallazgo crítico: una estrategia “talla única” no funciona. La calibración debe ser tailored — específicamente diseñada — por cada tipo de tarea.

Conclusión textual de los autores: “se requiere una estrategia tailored que empareje los modelos con tareas biomédicas y aplique correcciones apropiadas para alcanzar calibración óptima, y es esencial para toma de decisiones en contexto de salud; un approach ‘talla única’ no es suficiente.”

Por qué importa para el proyecto: el threshold de Test 4 (ECE menor a 0.10) es aproximadamente 3x más estricto que la calibración baseline encontrada en este estudio. Alcanzar ese threshold en 8 meses, sin investment técnico significativo en métodos de calibración por tipo de tarea, es ambicioso a la luz de esta evidencia.

Frente 4 · Más cómputo no necesariamente es mejor

Su et al., mayo 2025 — el experimento de “no pienses tanto”

Paper: “Don’t Overthink It. Preferring Shorter Thinking Chains for Improved LLM Reasoning.” arXiv:2505.17813.

Contexto: una técnica reciente conocida como “escalamiento en tiempo de inferencia” consiste en darle al modelo más cómputo para “pensar más” antes de responder. Esto se logra haciendo que el modelo genere cadenas de pensamiento más largas o ejecute múltiples pasadas de razonamiento. La intuición es que más pensamiento debería producir mejores respuestas. La realidad es más complicada.

Qué hicieron en el experimento: tomaron cuatro modelos de razonamiento líderes y, para cada pregunta de cuatro bancos de pruebas de razonamiento complejo, generaron múltiples respuestas con cadenas de pensamiento de diferentes longitudes. Después analizaron la relación entre longitud de la cadena y precisión de la respuesta.

Qué encontraron:

- Pensar más no necesariamente mejora el desempeño.
- En problemas simples, pensar más puede empeorar el desempeño dramáticamente.
- Hay una “longitud óptima” que depende del problema y del modelo, y excederla es contraproducente.
- Los modelos más recientes muestran un patrón de “sobrepensamiento” donde generan cadenas innecesariamente largas que llevan a respuestas peores que cadenas cortas.

Por qué importa para el proyecto: la intuición de que “darle más capacidad al sistema mejora la calidad” es falsa. Componentes que iteran sobre simulaciones, o que ejecutan múltiples pasadas de razonamiento, pueden estar empeorando sus outputs sin que sea evidente.

Agarwal et al., diciembre 2025 — el estudio empírico más grande sobre escalamiento

Paper: “The Art of Scaling Test-Time Compute for Large Language Models.” arXiv:2512.02008.

Qué hicieron en el experimento: estudio empírico masivo, abarcando más de 30 mil millones de tokens generados, usando 8 modelos diferentes (de 7 mil millones a 235 mil millones de parámetros), en 4 datasets de razonamiento.

Qué encontraron tres hallazgos consistentes:

1. Ninguna estrategia única de escalamiento de cómputo domina universalmente.

2. Los modelos de razonamiento exhiben patrones distintos de calidad de cadena según la dificultad del problema y la longitud de la cadena, formando categorías de “horizonte corto” y “horizonte largo.”
3. Para un tipo de modelo dado, el desempeño óptimo escala monótonamente con el presupuesto de cómputo — pero la estrategia óptima depende del problema, modelo, y presupuesto.

Por qué importa para el proyecto: no existe una receta universal para “más es mejor.” Cualquier decisión arquitectónica que asuma una relación lineal entre cómputo y calidad va a fallar.

Frente 5 • El cambio de fase positivo de 2025

Guo et al., enero 2025 (Nature septiembre 2025) — DeepSeek-R1

Paper: “DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning.” arXiv:2501.12948. Versión final publicada en *Nature*: doi:10.1038/s41586-025-09422-z.

Por qué este paper importa: *Nature* es una de las revistas científicas más rigurosas del mundo. Que un paper sobre razonamiento de modelos de lenguaje sea publicado ahí, después de revisión por pares, le da peso metodológico que la mayoría de papers en el campo no tienen.

Qué hicieron en el experimento: tomaron un modelo base (DeepSeek-V3) y lo entrenaron usando aprendizaje por refuerzo (en inglés *Reinforcement Learning*, abreviado *RL* — una técnica donde el modelo aprende mediante recompensas y castigos en lugar de simplemente imitar ejemplos). Lo crítico: NO le enseñaron previamente con ejemplos curados de razonamiento. La idea era ver si las capacidades de razonamiento podían “emerger” sin supervisión directa.

Qué encontraron:

- El modelo, llamado R1-Zero, pasó de 15.6% de acierto en un examen de matemáticas competitivas (AIME 2024) a 71.0%.
- Con ajustes adicionales, llegó a 86.7%, comparable al mejor modelo cerrado disponible (o1 de OpenAI).
- Más importante aún: durante el entrenamiento el modelo desarrolló comportamientos que no le fueron enseñados explícitamente. Empezó a auto-reflexionar sobre sus propias respuestas, a verificar pasos intermedios, a retroceder cuando se equivocaba, a probar estrategias alternativas. Estos comportamientos emergieron de la dinámica del entrenamiento por refuerzo.

Por qué importa para el proyecto: este paper es la evidencia más fuerte de que el razonamiento de los modelos no es estático ni fundamentalmente limitado. Hay un cambio de fase activo en cómo se entrenan los modelos para razonar. Los logros recientes son reales. Sin embargo — y esto es crucial — los problemas documentados en los frentes 1-4 (fragilidad, fidelidad, calibración, escalamiento) NO se resuelven con este enfoque. Mejor desempeño en bancos de pruebas no es equivalente a confiabilidad operacional en dominios novedosos.

Aichberger et al., marzo 2025 — análisis comprehensivo del estado del arte

Paper: “Reasoning Beyond Limits: Advances and Open Problems for LLMs.” arXiv:2503.22732.

Qué hicieron: análisis comprehensivo de los 27 modelos más importantes publicados entre 2023 y 2025, incluyendo Mistral AI Small 3 24B, DeepSeek-R1, Search-o1, QwQ-32B, y phi-4. Cubrieron metodologías de entrenamiento, arquitecturas, técnicas de cadena de pensamiento, escalamiento en tiempo de inferencia, distilación, y métodos de aprendizaje por refuerzo.

Qué encontraron: confirmación tanto de avances genuinos como de problemas persistentes. Identificaron explícitamente cuatro desafíos abiertos:

1. Mejorar el razonamiento multi-paso sin supervisión humana.
2. Superar limitaciones en tareas encadenadas.
3. Balancear prompts estructurados con flexibilidad.
4. Mejorar el retrieval de contextos largos y la integración con herramientas externas.

Por qué importa para el proyecto: los cuatro desafíos abiertos identificados en este paper son exactamente los que aplica el proyecto. El proyecto está apostando precisamente al espacio donde la literatura reconoce que hay tracción real pero también research abierto.

Lo que NO sobrevive el filtro

Tres áreas donde la evidencia previa ha sido revertida y por lo tanto no aparece en este análisis:

1. **Que los modelos no podían hacer matemáticas competitivas.** DeepSeek-R1 lo refuta: 71-86% en AIME 2024.
2. **Que necesitaban supervisión humana extensa para razonar bien.** R1-Zero lo refuta: razonamiento emergió de entrenamiento por refuerzo puro.

3. **Que el razonamiento no escalaba con cómputo.** El cambio de fase de “test-time compute” lo refuta parcialmente, aunque con caveats importantes (Su et al. 2025 muestra que más no siempre es mejor).

Parte 2 · Atacando el proyecto componente por componente

Ahora aplico la evidencia de la Parte 1 contra cada pieza de la arquitectura actual. Para cada componente: qué reclama hacer, qué evidencia lo amenaza, y dónde está expuesto realmente.

Componente 1 · El campo `framework_applied` en el output contract

Qué reclama hacer: cada agente que produce un output substrate-instrumentado declara qué framework de razonamiento usó (Chain-of-Thought, Tree-of-Thought, Self-Discover, Self-Consistency, Logic-LM, Inversion, First-Principles, Chain-of-Verification). Esto permite decompensar la calibración por framework, medir transferibilidad de frameworks entre dominios, y auditar el razonamiento del sistema.

Evidencia que lo amenaza:

El paper de Anthropic de abril 2025 es devastador para este componente específico. Si los modelos modernos (incluyendo Claude 3.7 Sonnet, que es el más sofisticado disponible al momento del paper) solo declaran honestamente sus pistas el 25-39% del tiempo cuando las usan, ¿qué garantía hay de que un modelo declare honestamente “usé Tree-of-Thought aquí” cuando en realidad usó pattern matching disfrazado de razonamiento estructurado? Probablemente ninguna garantía rigurosa.

El paper de Concept Walk de octubre 2025 agrega un matiz importante: en casos fáciles las cadenas de razonamiento son decorativas. Eso significa que el `framework_applied` puede ser literatura post-hoc generada para satisfacer el contract de output, no introspección genuina del proceso interno del modelo.

Dónde está expuesto:

- **Severamente expuesto** en la decomposición de calibración por framework. Si la etiqueta de framework es ruido auto-reportado, la decomposición es ruido. El equipo podría pasar 8 meses optimizando “calibración cuando se usa Tree-of-Thought vs Chain-of-Thought” basándose en datos que no significan lo que parecen significar.
- **Moderadamente expuesto** en la transferibilidad de frameworks entre dominios. Si el modelo dice “usé Inversion en organogénesis y también en cardiología”, pero en realidad ambos casos fueron pattern matching con etiqueta diferente, el reclamo de transferibilidad de frameworks es vacío.

Severidad del problema: alta. Este componente sostiene una pieza central del reclamo substrate del proyecto.

Componente 2 · El auditor SI/NO en Method 1

Qué reclama hacer: filtrar outputs del swarm de especialistas antes de que lleguen al primer human gate. Decide si un output es lo suficientemente bueno para escalar al siguiente paso del pipeline (sim orquestador, sim especialistas, segundo human gate).

Evidencia que lo amenaza:

Esta es la pieza más expuesta del proyecto entero. Un auditor LLM aplicando juicio binario (SI/NO) sufre de tres problemas documentados simultáneamente, cada uno suficiente para comprometerlo:

1. **Calibración pobre** (Vega et al. febrero 2025): el auditor está aproximadamente 30% off-target en su confianza. Cuando dice “este output es válido con 80% de confianza,” realmente acierta 50% del tiempo.
2. **Fidelidad cuestionable** (Anthropic abril 2025): la justificación que da el auditor para su decisión puede no ser la razón real por la que tomó la decisión. Auditar al auditor leyendo su explicación puede dar una falsa sensación de transparencia.
3. **Fragilidad a perturbaciones** (Mirzadeh 2024 no revertido, Roh junio 2025): pequeños cambios en cómo se presenta el output al auditor pueden voltear la decisión. Un output válido formateado diferente puede ser rechazado, y viceversa.

Heyman et al. (mayo 2025) agrega un cuarto problema específico: los modelos sistemáticamente alucinan features que no existen en el input. Un auditor puede rechazar un output válido porque “alucinó” que viola un constraint inexistente. O peor, aprobar un output inválido porque alucinó que cumple un criterio que no cumple.

Dónde está expuesto:

- **Severamente expuesto** en la cascada Method 1. Si el auditor falla 30% de las veces (consistente con la evidencia de calibración), un output incorrecto pasa el filtro y llega al sim orquestador. El sim corre sobre un input contaminado. El human gate 2 ve un output que ya pasó por dos capas de filtrado y está predispuesto a confiar en él. Los errores compounding.
- **Moderadamente expuesto** en auditoría de outputs largos o estructuralmente complejos. La interferencia proactiva (Wang & Sun 2025) sugiere que en outputs largos, lo primero que el auditor procesa puede disrumpir el procesamiento de lo posterior, sin que sea evidente.

Severidad del problema: muy alta. Si el auditor de Method 1 es estructuralmente poco confiable, todo Method 1 hereda esa poca confiabilidad.

Componente 3 • `calibration-tracker` agent (encargado de Test 4)

Qué reclama hacer: trackear la confianza reportada en cada output, comparar con outcomes reales, calcular métricas de calibración (Expected Calibration Error y Brier Score) decompuestas por framework de razonamiento.

Evidencia que lo amenaza:

Vega et al. (febrero 2025) es la evidencia más directa y preocupante. La calibración baseline de modelos en biomedicina es aproximadamente 30% off-target. Esto significa que el `calibration-tracker` va a estar midiendo un sistema profundamente miscalibrado por meses antes de que las correcciones post-hoc empiecen a funcionar. **El threshold de Test 4 (ECE menor a 0.10, accuracy mayor o igual a 85% en outputs de alta confianza) es ambicioso a la luz de esta evidencia.**

Si el baseline es 30% off-target y el target es menos de 10%, eso requiere mejora de aproximadamente 3x en calibración. La literatura demuestra que los métodos post-hoc (regresión isotónica, agrupamiento por histograma, escalado de Platt) ayudan pero no logran esa magnitud de mejora sin investment técnico dedicado.

El paper de Vega también encontró que “one-size-fits-all approach is not sufficient” — la calibración debe ser tailored por tipo de tarea. Esto significa que el `calibration-tracker` no puede tener un solo método de calibración global; necesita un método por categoría de output, calibrado independientemente.

Dónde está expuesto:

- **Estructuralmente expuesto.** Test 4 es probablemente el test que más está apostando contra evidencia adversa. La probabilidad de que se cumplan los thresholds en 8 meses sin investment técnico significativo es baja según la literatura.
- **Operacionalmente expuesto.** Si el `calibration-tracker` mide calibración decompuesta por framework, y los frameworks son self-reported por el modelo (ver Componente 1), las decomposiciones son ruido sobre ruido — etiquetas no confiables aplicadas a métricas que también tienen incertidumbre alta.

Severidad del problema: alta. Este es un caso donde un threshold optimista colisiona con una baseline pesimista en la literatura.

Componente 4 • `causal-pruner` (active learning sobre intervenciones)

Qué reclama hacer: usar razonamiento sobre outputs de simulación para rankear candidatos de intervención biológica. Active learning sobre el espacio de podas posibles.

Evidencia que lo amenaza:

Aquí la exposición es más sutil y más interesante. El causal-pruner depende fuertemente de razonamiento causal — exactamente el tipo de razonamiento donde la literatura 2025 muestra resultados mixtos.

Magraner et al. (agosto 2025) específicamente prueba “atribución causal” como una de las cuatro familias de razonamiento clínico, y los modelos rinden pobremente. Los modelos “carecen de las representaciones internas estructuradas y composicionales necesarias para integrar constraints, ponderar evidencia, simular contrafactuales.”

Khalid et al. (marzo 2025) sobre razonamiento disjuntivo es directamente relevante: el active learning sobre intervenciones requiere considerar múltiples caminos causales en paralelo y compararlos. Es decir, requiere exactamente el tipo de razonamiento que el paper identifica como problemático.

Dónde está expuesto:

- **Severamente expuesto** en el ranking causal. El ranking asume que el modelo puede razonar comparativamente sobre intervenciones. La evidencia sugiere que puede pattern-matchear sobre intervenciones similares vistas en entrenamiento, pero no razonar genuinamente sobre causalidad estructurada en casos novedosos.
- **Moderadamente expuesto** en la integración con simulation outputs. Si el causal-pruner está mal interpretando lo que la simulación dice, el ranking podría reflejar el sesgo del modelo más que las propiedades del sistema simulado.

Severidad del problema: alta. El causal-pruner es una pieza central del POC biológico.

Componente 5 • `cross-field-bridge-agent` (encargado de Test 5)

Qué reclama hacer: reconocer cuándo una pregunta de organogénesis se beneficia de framing desde el partner field (TBD: cardiología u oftalmología). Invocar herramientas del partner field. Interpretar resultados en términos de biología del desarrollo.

Evidencia que lo amenaza:

Este es probablemente el componente más especulativo del proyecto y la evidencia 2025+ no lo ayuda. La transferencia productiva entre dominios estructuralmente distintos no está bien estudiada en la literatura — es research abierto.

Más importante: la evidencia de Magraner et al. (agosto 2025) sobre dissociation knowledge-reasoning sugiere que aunque el modelo *tenga* conocimiento de cardiología y de organogénesis simultáneamente (lo que probablemente sea cierto), eso no garantiza que pueda *integrar* ambos para producir insight cross-field. La integración estructural es exactamente la capacidad que falta.

Aichberger et al. (marzo 2025) en su análisis de 27 modelos identifica explícitamente “long-context retrieval and external tool integration” como uno de los desafíos abiertos del campo.

Dónde está expuesto:

- **Estructuralmente expuesto.** Test 5 es la apuesta más ambiciosa del proyecto y la que tiene menos respaldo en literatura existente. Que se cumpla a niveles meaningful en 8 meses es optimista.
- **Operacionalmente expuesto.** La elección entre cardiología vs oftalmología no resuelve el problema fundamental — ningún partner field garantiza que el modelo logre integración estructural genuina.

Severidad del problema: alta, pero el proyecto ya intuyó esto al posicionar Test 5 como exploratorio y diferir la decisión del partner field.

Componente 6 • Method 1 vs Method 2 — la elección arquitectural

Qué reclama hacer: Method 1 (orquestrado) para tareas de alto volumen donde el substrate ya tiene cobertura. Method 2 (dirigido por humano) para preguntas novedosas o de alto riesgo.

Evidencia que lo amenaza/respalda:

La evidencia 2025+ es contundente: Method 2 está sustancialmente más respaldado que Method 1. El proyecto ya intuyó esto correctamente al diseñar la dual-method architecture, pero la magnitud de la diferencia probablemente esté subestimada.

Para Method 1, los problemas son acumulativos: el orquestador toma decisiones (con calibración pobre y fidelidad cuestionable), el swarm produce outputs (con fragilidad a perturbaciones), el auditor filtra (heredando todos los problemas anteriores y agregando los suyos), y solo entonces el humano interviene. Cada capa multiplica los modos de fallo.

Para Method 2, el humano dirige las decisiones estratégicas y los modelos ejecutan tareas más acotadas. Los modos de fallo individuales son los mismos pero su impacto está contenido por la presencia humana frecuente. El humano es el calibrador de confianza por default, lo que sortea el problema de calibración pobre del modelo.

Su et al. (mayo 2025, “Don’t Overthink It”) agrega un punto interesante: a veces más cómputo autónomo empeora el resultado. Eso favorece Method 2 sobre Method 1 estructuralmente, no solo operacionalmente.

Dónde está expuesto:

- **Method 1 está estructuralmente expuesto** a todos los problemas del campo simultáneamente. La filosofía de “Method 2 outer loop, Method 1 inner loop” en el scope doc es probablemente una buena heurística, pero el “inner loop” debe ser realmente acotado — no debe procesar decisiones de impacto sin retorno al humano.
- **Method 2 está moderadamente expuesto** en su componente `accumulator`, que tiene que sintetizar outputs de especialistas en una thesis coherente. Esa síntesis es razonamiento composicional — exactamente el tipo donde los modelos fallan según Khalid et al. 2025.

Severidad del problema: alta para Method 1, moderada para Method 2.

Componente 7 • DATA INAMOVIBLE (la base de conocimiento compartida)

Qué reclama hacer: base de conocimiento curada y versionada con priors de pez cebra, literatura de desarrollo renal, documentación de simulación, archivos de experimentos previos, y referencias del partner field.

Evidencia que lo amenaza/respalda:

Brown et al. (agosto 2025) revisó 128 papers sobre Retrieval-Augmented Generation entre 2020 y 2025. La conclusión general: RAG sí reduce alucinaciones y mejora actualización de conocimiento, pero los beneficios dependen críticamente del diseño específico.

Lo más relevante para el proyecto: el sistema BTE-RAG en biomedicina (Wright et al. 2025) demostró que integrar 60+ fuentes biomédicas mejora sustancialmente la precisión. Pero también mostró que la calidad depende de cómo se diseñan las consultas y cómo se presenta la evidencia recuperada al modelo.

Magraner et al. (agosto 2025) es importante aquí porque sugiere que el problema NO es knowledge access — los modelos ya tienen el conocimiento. El problema es structured deployment de ese conocimiento. **Esto significa que invertir mucho upfront en una arquitectura RAG sofisticada (por ejemplo, knowledge graph elaborado con relaciones complejas) puede ser optimización prematura.**

Dónde está expuesto:

- **Bajamente expuesto.** Es probablemente uno de los componentes más sólidos del proyecto. RAG funciona razonablemente bien, especialmente en biomedicina.
- **Moderadamente expuesto** en el diseño de las consultas. Si las consultas están mal formadas, recuperan contenido semánticamente similar pero lógicamente irrelevante.

Severidad del problema: baja. Pero la decisión arquitectónica entre RAG simple vs knowledge graph elaborado merece ser reconsiderada a la luz de esta evidencia.

Componente 8 · Los 8 frameworks del catálogo

Qué reclama hacer: operacionalizar 8 frameworks de razonamiento como herramientas que los agentes pueden invocar — Chain-of-Thought, Tree-of-Thought, Self-Discover, Self-Consistency, Logic-LM, Inversion, First-Principles, Chain-of-Verification.

Evidencia que lo amenaza/respalda — framework por framework:

- **Chain-of-Thought:** la evidencia 2025+ es mixta. Wei (2022) la introdujo, pero Anthropic 2025 mostró que las cadenas frecuentemente no son fieles al razonamiento real. Heyman 2025 mostró que se acentúan ciertos modos de fallo cuando se usa en problemas constraint-heavy. **Veredicto:** sigue siendo útil pero no como “ventana al razonamiento del modelo.” Es una herramienta de prompting que produce outputs estructurados, no un mecanismo de auditoría.
- **Tree-of-Thought:** la evidencia es escasa en 2025+. Sigue siendo prometedor pero está parado en un proceso (rama múltiple) que la literatura sobre razonamiento disjuntivo (Khalid 2025) sugiere problemático. **Veredicto:** usar con cautela en problemas exploratorios.
- **Self-Discover:** evidencia escasa post-2024. **Veredicto:** mantener pero monitorear.
- **Self-Consistency:** uno de los frameworks mejor respaldados por evidencia 2025+. La votación entre múltiples runs es exactamente la mitigación que la literatura recomienda para fragilidad. Vega et al. 2025 lo usó como una de las tres estrategias de confidence scoring exitosas. **Veredicto:** muy sólido. Probablemente subutilizado en el catálogo actual.
- **Logic-LM:** evidencia 2025+ favorable. Cuando el problema es codificable formalmente, los métodos simbólicos siguen produciendo resultados perfectamente calibrados por construcción — algo que ningún modelo neural alcanza. **Veredicto:** muy sólido para compliance y constraint satisfaction. Probablemente subutilizado.
- **Inversion (Munger):** no tiene evidencia técnica directa en literatura LLM 2025+, pero como heurística de prompting es defendible.
- **First-Principles:** misma situación — heurística de prompting útil pero sin literatura técnica que la valide rigurosamente.
- **Chain-of-Verification (Dhuliawala 2024):** la evidencia 2025+ sigue favoreciendo verificación step-by-step. Pero también la evidencia de “Don’t Overthink It” (Su 2025) sugiere que verificación excesiva puede empeorar resultados en problemas simples. **Veredicto:** útil pero context-dependent.

Dónde está expuesto:

- **Moderadamente expuesto.** El catálogo asume que los frameworks son herramientas independientes con valor comparable. La realidad de la evidencia es que **algunos frameworks (Self-Consistency, Logic-LM) son sustancialmente mejores que otros, y deberían ser default no opciones.**

Severidad del problema: moderada. Solucionable con re-priorización del catálogo.

Componente 9 · Test 3 (Iteration Loop) — el reclamo de mejora con uso

Qué reclama hacer: demostrar que el sistema mejora medible y consistentemente con feedback durante el año (+15 puntos porcentuales en accuracy, +0.15 en calibración, cero degradación).

Evidencia que lo amenaza:

Aquí el problema no es evidencia adversa — es ausencia de evidencia. La literatura 2025+ sobre measurable improvement en sistemas de producción durante un año, específicamente atribuible a feedback acumulado, es escasa. La mayoría del trabajo es sobre fine-tuning batch o sobre aprendizaje por refuerzo en entrenamiento, no sobre accumulation-through-deployment.

DeepSeek-R1 demostró improvement dramático con aprendizaje por refuerzo, pero eso es entrenamiento intensivo en una fase dedicada, no “compound through use” durante operación.

Dónde está expuesto:

- **Estructuralmente expuesto.** La magnitud reclamada (+15 puntos porcentuales accuracy, +0.15 calibración) es ambiciosa para un POC de 8 meses. La literatura no la respalda ni la refuta porque casi no existe trabajo sistemático en ese horizonte temporal y con ese mecanismo.
- **Metodológicamente expuesto.** La baseline de mes 0 estará contaminada por brittleness (Mirzadeh, Roh). Si el sistema “mejora” 10 puntos porcentuales entre mes 0 y mes 8, parte de eso puede ser ruido estadístico, no improvement genuino.

Severidad del problema: alta, pero más por incertidumbre metodológica que por evidencia adversa específica.

Síntesis del ataque · ranking de componentes por exposición

Los tres componentes más vulnerables (orden de severidad):

1. **El campo `framework_applied` y la decomposición de calibración por framework.** Toda la pieza de “evidencia substrate decompuesta por framework” depende de que el modelo declare honestamente qué framework usó. La evidencia de Anthropic 2025 dice que esa declaración es 25-39% confiable. Esto contamina meses potenciales de evidencia substrate.
2. **El auditor SI/NO de Method 1.** Combina simultáneamente los tres problemas peor documentados (calibración pobre, fidelidad cuestionable, fragilidad a perturbaciones). Como nodo cascada en la pipeline, sus errores se propagan hacia adelante.
3. **Test 4 (Calibración) en sus thresholds actuales.** El threshold ECE menor a 0.10 es 3x más estricto que lo que la literatura sugiere alcanzable en 8 meses sin investment técnico significativo en métodos de calibración tailored por tipo de tarea.

Los tres componentes más sólidos:

1. **DATA INAMOVIBLE con RAG simple.** La evidencia 2025+ favorece este approach. Es probablemente el componente menos vulnerable.
2. **Self-Consistency y Logic-LM como frameworks default.** Ambos tienen respaldo sólido en evidencia 2025+ y resuelven (parcialmente) los problemas que aquejan a otros frameworks.
3. **Method 2 (human-driven).** La literatura no le da los problemas de cascada que Method 1 sí tiene. La presencia humana frecuente contiene los modos de fallo.

Lo que NO está atacado por la evidencia:

- **Witt como concepto general no es refutado por la literatura 2025+.** El framing del substrate (capturar juicio experto calibrado, exponer razonamiento, crecer con uso) es coherente con lo que la literatura identifica como gaps reales. Lo que la literatura desafía no es el qué — es el cuán rápido y cuán completo. Los thresholds de los tests son lo más expuesto, no el approach mismo.
- **El POC biológico (organogénesis) no es atacado por esta evidencia en absoluto.** La biología es la biología. Los validation gates biológicos (Induction, Specificity, Identity, Parsimony) están protegidos del problema del razonamiento de modelos porque son medidos con readouts experimentales, no con juicio LLM.

Parte 3 · Ajustes arquitectónicos propuestos

Ahora la pregunta importante: ¿qué hacemos con esto? La evidencia no demanda replanteo fundamental, pero sí varias recalibraciones operativas y arquitectónicas. Estas son las propuestas concretas, organizadas por componente.

Ajuste 1 · Reformular el campo `framework_applied` como self-report no introspectivo

El problema actual: el documento `substrate-evidence-guide.md` describe el campo `framework_applied` como si fuera una declaración fiel del proceso interno del agente. La evidencia muestra que es, en el mejor caso, una etiqueta auto-reportada que correlaciona parcialmente con el proceso interno.

El ajuste propuesto: modificar la descripción del campo en `substrate-evidence-guide.md` con un disclaimer explícito:

El campo `framework_applied` es una declaración auto-reportada del agente sobre qué framework de razonamiento intentó aplicar al producir su output. NO debe interpretarse como introspección verdadera del proceso interno del modelo. Evidencia 2025 (Anthropic, abril 2025) muestra que los modelos modernos solo reportan honestamente las influencias en su razonamiento entre 25% y 39% de las veces. Por lo tanto:

- El campo debe ser usado para decompensar evidencia por categoría de framework, no para auditar fidelidad del razonamiento.*
- La calibración debe medirse contra outcomes reales, no contra la pretensión de qué framework “realmente operó internamente.”*
- Cuando se reporten findings que dependan de este campo, debe nombrarse explícitamente la limitación.*

Impacto: mínimo en código, importante en interpretación. No requiere cambios en agentes existentes, solo en cómo se interpreta la evidencia que producen.

Ajuste 2 · Replantear el auditor SI/NO de Method 1

El problema actual: un solo modelo dando juicio binario sobre outputs, expuesto a tres problemas estructurales documentados.

El ajuste propuesto: convertir el “auditor” en un componente compuesto con tres modos de operación según el tipo de output:

- **Modo Self-Consistency mandatory:** para outputs estructurados donde una respuesta correcta puede ser mayoría. El auditor ejecuta entre 5 y 7 instancias del juicio en paralelo (con temperatura mayor a 0) y reporta tanto la decisión mayoritaria como la tasa de acuerdo. Si la tasa de acuerdo es menor a un threshold (por ejemplo 70%), el output se escala automáticamente a human gate sin filtrado.
- **Modo Logic-LM mandatory:** para outputs donde los criterios son codificables formalmente — compliance regulatorio (IACUC, ISSCR, IBC), restricciones de presupuesto, restricciones de plazos, restricciones de seguridad. La validación se hace con un solver simbólico, no con juicio de modelo. Esto produce decisiones perfectamente calibradas por construcción.
- **Modo human gate antes que auditor:** para outputs por encima de un threshold de impacto (por ejemplo, decisiones que afectan budget burn, o que cambian dirección experimental). Estos outputs no pasan por el filtro automático — van directamente a humano.

El auditor actual de un solo modelo se reduce a un caso residual: solo opera en outputs donde Self-Consistency no aplica, Logic-LM no aplica, y el impacto es bajo. Esos casos serán pocos.

Impacto: requiere reescribir la spec del auditor en el catálogo de agentes. No requiere infraestructura nueva — Self-Consistency es múltiples llamadas al mismo modelo, Logic-LM se puede implementar con solvers Python (Z3, por ejemplo).

Ajuste 3 · Recalibrar los thresholds de Test 4 (Calibración)

El problema actual: el threshold ECE menor a 0.10 es ambicioso a la luz de la evidencia. La probabilidad de cumplirlo en 8 meses sin investment técnico significativo es baja.

El ajuste propuesto: dividir el threshold actual en tres niveles:

- **Threshold defensivo (compromiso del proyecto):** ECE menor a 0.20. Esto es alcanzable con métodos post-hoc estándar y es defendible como mejora real sobre baseline.
- **Threshold ambicioso (objetivo aspiracional):** ECE menor a 0.10. Esto se mantiene como objetivo pero se reporta como aspiracional, no como criterio de éxito hard.
- **Threshold por tipo de tarea:** decompensar las métricas no solo por framework (que es self-reported, ver Ajuste 1) sino también por categoría objetiva de tarea (clasificación binaria, ranking, extracción, generación). Reportar calibración por categoría, no solo agregada.

Impacto: requiere actualizar el scope doc en la sección de Test 4. No requiere cambios técnicos en el `calibration-tracker` — solo en cómo se reporta lo que mide.

Ajuste 4 · Aplicar regresión isotónica e histogram binning desde el día 1

El problema actual: los métodos post-hoc de calibración están planeados como “afterthought” cuando llegue el ML researcher. La evidencia (Vega 2025) sugiere que aplicarlos desde el inicio — incluso en formas básicas — produce mejora sustancial.

El ajuste propuesto: implementar regresión isotónica e histogram binning desde el primer batch de eval del `evaluation-runner`. Estos son métodos estándar disponibles en cualquier librería de calibración (sklearn, por ejemplo). No requieren expertise especializado para una versión inicial.

La línea base de calibración del proyecto debe ser “modelo + correcciones post-hoc básicas,” no “modelo crudo.” Esto define la baseline contra la cual se mide improvement.

Impacto: requiere agregar una dependencia técnica al `calibration-tracker`. Implementación de unas decenas de líneas de Python.

Ajuste 5 · Tratar al `causal-pruner` como herramienta de hipótesis, no como decision-maker

El problema actual: el `causal-pruner` rankea intervenciones, y la implementación actual sugiere que ese ranking es input directo a la siguiente fase.

El ajuste propuesto: explicitar que el ranking del `causal-pruner` es input a humano, no decisión final:

- Cada ranking del `causal-pruner` debe pasar por revisión humana antes de afectar el experimento real.
- Validar el `causal-pruner` contra ground truth conocido en mini-benchmarks antes de soltarlo sobre intervenciones nuevas. Esto produce evidencia de qué tan bien rankea cuando sí sabemos la respuesta correcta.
- Considerar arquitectura híbrida: el `causal-pruner` propone, un componente formal (con Logic-LM verificando consistencia interna) revisa, y humano decide.

Impacto: principalmente conceptual. Requiere actualizar la descripción del `causal-pruner` y el flujo de decisión en torno a él.

Ajuste 6 · Method 1 como caso minoritario en Phase I, no mayoritario

El problema actual: el documento de scope sugiere que Method 1 es un modo principal de operación. La evidencia favorece Method 2 estructuralmente.

El ajuste propuesto: explicitar que en Phase I, Method 1 se reserva para tareas de muy bajo riesgo donde los errores son fácilmente reversibles:

- Literature monitoring (recolectar y resumir papers nuevos).
- Agendamiento operacional (calendario, recordatorios).
- Formatting de outputs.
- Tracking de inventario de reagentes.
- Checks de consistencia simples.

Method 2 se usa para todo lo demás en Phase I. Method 1 se considera para escalar progresivamente a más tipos de tareas en Phase II y III, conforme acumulemos evidencia de calibración suficiente para hacer confiables sus juicios autónomos.

Impacto: ajuste de filosofía operativa. Cambia cómo se asignan tareas a modos, no la arquitectura misma.

Ajuste 7 · Reordenar la prioridad de los frameworks del catálogo

El problema actual: el catálogo de 8 frameworks los presenta como herramientas con valor comparable. La evidencia 2025+ sugiere que algunos son sustancialmente más sólidos que otros.

El ajuste propuesto: reorganizar el catálogo en niveles según fortaleza de evidencia:

- **Nivel 1 (default cuando aplique):** Self-Consistency, Logic-LM. Estos son los frameworks con evidencia técnica más sólida y deberían ser preferidos cuando aplique su dominio.
- **Nivel 2 (úsalos con awareness de limitaciones):** Chain-of-Thought, Chain-of-Verification, Tree-of-Thought, Self-Discover. Útiles pero con caveats documentados.
- **Nivel 3 (heurísticas de prompting útiles, sin evidencia técnica formal):** Inversion, First-Principles. No están refutados — simplemente no tienen estudios rigurosos en literatura LLM. Mantenerlos como heurísticas, marcadas como tales.

Cada agente que invoque un framework debe documentar por qué eligió el nivel que eligió.

Impacto: requiere actualizar `reasoning-frameworks-catalog.md` con esta jerarquía. Documentación, no código.

Ajuste 8 · Empezar con RAG simple, no con knowledge graph elaborado

El problema actual: la decisión “RAG vs knowledge graph” para DATA INAMOVIBLE está abierta y propensa a optimización prematura.

El ajuste propuesto: empezar con RAG simple (vector search sobre la knowledge base existente) y medir empíricamente cuál es el cuello de botella real:

- Si el cuello de botella es access (los modelos no están encontrando la información correcta): invertir en mejor retrieval.

- Si el cuello de botella es razonamiento (los modelos encuentran la información pero no saben qué hacer con ella): invertir en estructura de prompts y en frameworks como Self-Consistency.

Magraner et al. (agosto 2025) sugiere que el cuello de botella probablemente sea el segundo, no el primero. Pero la decisión debe basarse en data del proyecto, no en literatura general.

Impacto: difiere una decisión arquitectónica importante hasta tener evidencia operativa. Aplica el principio “prueba pequeño antes de armar bien” literalmente.

Ajuste 9 · Hacer del `evaluation-runner` resistente a brittleness

El problema actual: el `evaluation-runner` corre el eval set en meses 0, 4 y 8. Una sola pasada por batch.

El ajuste propuesto: el `evaluation-runner` debe correr cada batch del eval set múltiples veces con perturbaciones controladas, y reportar mean $\pm$ std, no solo el número punta:

- **Perturbación numérica:** si la pregunta involucra números, generar variantes con números diferentes (ver Mirzadeh 2024).
- **Perturbación de orden:** si la pregunta tiene ejemplos, reordenarlos (ver Roh 2025).
- **Perturbación de superficie:** reformular la misma pregunta de 3-5 maneras (ver Roh 2025).

Para cada pregunta del eval set, ejecutar entre 3 y 5 versiones perturbadas y reportar:

- Acierto promedio.
- Desviación estándar del acierto.
- Si el modelo falla en alguna versión perturbada pero acierta en otras: flag explícito.

Esto convierte el eval set en una medición de robustez, no solo de capacidad.

Impacto: aproximadamente 3-5x más cómputo en evaluación. Pero las evaluaciones son raras (3 al año), así que el cómputo total agregado es manejable.

Ajuste 10 · Test 5 explícitamente exploratorio

El problema actual: Test 5 está descrito con thresholds específicos ($\geq 60\%$ invoca cross-field, $\geq 70\%$ uso apropiado, $\geq 30\%$ surfacing novel). La evidencia sugiere que esos thresholds son ambiciosos a la luz del estado del campo.

El ajuste propuesto: reposicionar Test 5 como exploratorio para Phase I:

- El criterio de éxito en Phase I se baja a “el sistema produce evidencia preliminar (incluso modesta) de que la transferencia entre dominios es posible.”
- Bajar los thresholds ilustrativos a algo más calibrado: $\geq 30\%$ invocación, $\geq 50\%$ uso apropiado, $\geq 10\%$ surfacing novel.
- Mantener los thresholds ambiciosos como aspiracionales para Phase II o III.
- La decisión cardiología vs oftalmología puede deferrarse aún más sin penalty real.

Impacto: ajuste al scope doc. No requiere cambios en `cross-field-bridge-agent`.

Síntesis de ajustes · qué cambia y qué se mantiene

Lo que cambia:

- Reformulación interpretativa del campo `framework_applied` (no introspección, self-report).
- Replanteo del auditor de Method 1 (Self-Consistency + Logic-LM mandatory según contexto).
- Recalibración de thresholds en Test 4 (defensivo + ambicioso + por categoría).
- Aplicación de métodos post-hoc de calibración desde el día 1.
- Reposicionamiento del `causal-pruner` como herramienta de hipótesis.
- Method 1 como caso minoritario en Phase I.
- Jerarquización de los frameworks del catálogo por fortaleza de evidencia.
- Decisión RAG simple, diferimiento de knowledge graph.
- `evaluation-runner` con perturbaciones para medir robustez.
- Test 5 explícitamente exploratorio con thresholds bajados.

Lo que NO cambia:

- Los 5 substrate validation tests como conceptos.
- La arquitectura dual-method como diseño general.
- El catálogo de 8 frameworks (solo se reorganiza prioridad).
- Los 25 agentes en 6 categorías (algunos cambian sus specs internas).

- El POC biológico — la biología está protegida del problema de razonamiento por sus readouts experimentales.
- El principio operativo de Martín (“prueba pequeño antes de armar bien”), que de hecho se refuerza con esta evidencia.

Parte 4 · Lo que el proyecto tiene a favor

Después de tres partes de stress-test, esta parte balancea honestamente lo que la evidencia 2025+ respalda del approach actual. No matiza los problemas — los problemas son reales — pero nombra concretamente qué partes del proyecto están en terreno sólido, qué precedentes existen, y qué del trabajo que el equipo ya hizo merece reconocimiento explícito.

Tres preguntas estructuran esta parte:

1. ¿La tesis del proyecto está en territorio empíricamente accesible, o estamos intentando algo que la literatura sugiere imposible?
2. ¿Qué empresas y proyectos académicos están haciendo cosas comparables, y cómo les está yendo?
3. ¿Qué decisiones arquitectónicas que el equipo ya tomó están explícitamente respaldadas por la evidencia?

La tesis está en territorio empíricamente accesible

El reclamo central del proyecto puede formularse así: que un sistema multi-agente basado en modelos de lenguaje grandes, con frameworks de razonamiento explícitos, supervisión humana estructurada, y mecanismos de calibración acumulativa, puede producir valor real en un dominio biomédico cuando se valida contra outcomes experimentales reales.

La evidencia 2025+ no refuta este reclamo. Lo respalda con matices.

Boiko et al., julio 2025 — sistemas multi-agente cerrando el loop con biología real.

Este paper, publicado en bioRxiv (doi:10.1101/2025.06.24.661378), describe un sistema multi-agente integrado con plataformas automatizadas de cultivo celular y metabolómica para descubrimiento científico autónomo en biología de sistemas. Validaron el sistema en *Saccharomyces cerevisiae* (levadura), identificando interacciones biológicas novedosas, incluyendo inhibición sinérgica del crecimiento inducida por glutamato en células tratadas con espermina, y rescate parcial del estrés por ácido fórmico mediante aminoácidos.

Lo crítico para el proyecto: **es exactamente la misma estructura conceptual** — modelos de lenguaje + framework de razonamiento explícito + validación experimental real + integración con automatización de laboratorio. Los autores describen explícitamente cómo combinan los modelos con scaffolds matemáticos y generación lógica de hipótesis para reducir incoherencia y mejorar confiabilidad. Y produjeron resultados biológicos reales que se validaron.

Implicación para el proyecto: la arquitectura general que estamos proponiendo no es especulativa. Hay precedente publicado de 2025 con resultados biológicos concretos. El proyecto está dentro del envelope de lo demostrado.

BioLab, septiembre 2025 — multi-agent system con foundation models biológicos.

Otro paper de bioRxiv (doi:10.1101/2025.09.03.674085) describe un sistema llamado BioLab que integra foundation models biológicos en un sistema multi-agente para investigación end-to-end en ciencias de la vida. Los autores validaron el sistema en un closed-loop con wet-lab, incluyendo el descubrimiento de hallazgos relacionados con células T.

El paper reconoce explícitamente las limitaciones de modelos de lenguaje generalistas en biología, citando la propensión a alucinaciones y la falta de fluidez en el lenguaje específico del dominio. Su solución arquitectónica es exactamente la que el proyecto propone: integración profunda con conocimiento de dominio, frameworks específicos, y supervisión estructurada.

Implicación para el proyecto: la combinación de foundation models con instrumentación específica de dominio tiene tracción real en biología en 2025. La intuición arquitectónica del proyecto está alineada con el state-of-the-art académico.

Recursion Pharmaceuticals — escala industrial de validación experimental con AI.

Citado en un survey de diciembre 2025 (arXiv:2512.04854, “From Task Executors to Research Partners”), Recursion Pharmaceuticals reporta ejecutar 2.2 millones de experimentos por semana mediante automatización guiada por inteligencia artificial. Esto no es proof-of-concept — es operación industrial. Y sus reportes recientes muestran que el approach AI-guided produce resultados biológicos reproducibles a escala.

Implicación para el proyecto: existen empresas valuadas en miles de millones de dólares que están operando exactamente en el cruce de modelos de IA con validación experimental biológica, a escala industrial. El espacio del proyecto es real, no especulativo.

Trehan & Chopra, enero 2026 — el contraejemplo honesto.

Este paper (arXiv:2601.03315) reporta cuatro intentos de generar papers de investigación científica de manera completamente autónoma con un pipeline de seis agentes. Tres de los cuatro fallaron. El que funcionó pasó revisión humana y multi-IA en un venue experimental.

Los seis modos de fallo recurrentes que documentaron son enormemente educativos para el proyecto:

1. Sesgo hacia los defaults del entrenamiento.
2. Drift de implementación bajo presión de ejecución.
3. Degradación de memoria y contexto en tareas de horizonte largo.
4. Sobre-entusiasmo declarando éxito a pesar de fallos obvios.
5. Inteligencia de dominio insuficiente.
6. Gusto científico débil en diseño experimental.

Implicación para el proyecto: el approach completamente autónomo (Method 1 sin gates) falla 75% del tiempo en este experimento controlado. **Eso es exactamente lo que el proyecto ya predijo al diseñar Method 2 con human-in-the-loop como modo principal.** La arquitectura dual con énfasis en supervisión humana no es paranoia — es alineamiento con evidencia empírica reciente.

Hay un ecosistema completo construyendo lo mismo

El proyecto no está solo en este territorio. Hay una industria emergente en 2025 dedicada exactamente a la infraestructura de evaluación, calibración, y operación confiable de sistemas multi-agente. Esto importa por dos razones: confirma que el espacio es viable, y proporciona herramientas que el proyecto puede usar.

Bessemer Venture Partners, agosto 2025, “The State of AI 2025.”

Este reporte de uno de los fondos más establecidos de venture capital identifica explícitamente que startups como Braintrust, LangChain, Bigspin.ai, y Judgment Labs están construyendo “the infrastructure stack for this new era” — eval harnesses, agentic benchmarking environments, real-time feedback loops. El reporte específicamente identifica “compound AI systems that don’t just focus on raw model horsepower but combine components such as knowledge retrieval, memory, planning, and inference optimization” como una de las direcciones más prometedoras.

Implicación para el proyecto: la categoría de “compound AI systems” que el proyecto está construyendo es una categoría reconocida y financiada por capital institucional. No es una categoría inventada por el equipo.

Judgment Labs (San Francisco, fundada 2025).

Esta empresa construye infraestructura para monitoreo del comportamiento de agentes (en inglés Agent Behavior Monitoring), proporcionando herramientas para trackear, evaluar, y mejorar la confiabilidad de workflows multi-step de IA en tiempo real, particularmente para deployment en producción. Tienen un framework open-source llamado Judgeval. Targets sectores como legal AI, soporte interno empresarial, y AI financiero.

Implicación para el proyecto: el problema de “tener un substrate-instrumented system con observabilidad y mejoramiento continuo” es un problema reconocido con dedicated tooling comercial. El proyecto puede aprender de cómo Judgment Labs aborda esto, e incluso considerar usar herramientas como Judgeval para partes del stack.

Menlo Ventures, diciembre 2025, “State of Generative AI in the Enterprise.”

Reporte que documenta inversión empresarial de 18 mil millones de dólares en 2025 en infraestructura de IA, modelos foundation, sistemas de entrenamiento, y capas de orquestación. Identifican que “AI became the fastest-scaling software category in history.” Una de sus cinco predicciones para el siguiente año: “AI will exceed human performance in daily practical programming tasks. There is no plateauing of LLM skill sets, especially in verifiable domains such as math and programming, where the best models will continue to get better and better.”

Implicación para el proyecto: la curva de capacidad de los modelos no está aplanándose. Lo que hoy son las limitaciones documentadas en la Parte 1 puede no serlo en 12-18 meses. El proyecto está apostando a una infraestructura que se beneficia directamente de las mejoras del state-of-the-art.

Las decisiones arquitectónicas del equipo ya están explícitamente respaldadas

Mucho del trabajo que el equipo ya hizo en el diseño actual está alineado con lo que la evidencia 2025+ recomienda. Esto merece reconocimiento explícito porque no es accidental — es el resultado de buen juicio aplicado iterativamente.

Decisión 1: Method 2 con human-in-the-loop como modo principal.

La revisión sistemática de Human-in-the-Loop AI publicada en marzo 2026 (mdpi.com/1099-4300/28/4/377) sintetiza evidencia de healthcare, sistemas autónomos, ciberseguridad, y otros dominios de alto riesgo donde la supervisión humana es esencial. La conclusión: en aplicaciones high-stakes, la automatización completa permanece insuficiente, y la integración del juicio humano en sistemas de IA es una dirección de investigación clave.

Específicamente para healthcare y life sciences: una review publicada en febrero 2026 en ScienceDirect documenta que “human-in-the-loop AI demonstrates significant applications across diagnostic imaging, clinical decision support, patient monitoring, drug discovery, and research data analysis. Evidence indicates improved diagnostic accuracy, reduced medical errors, enhanced patient safety, and increased clinician trust compared to both automated AI and traditional approaches.”

Lo que esto significa: la decisión de hacer Method 2 (human-driven) el modo principal del proyecto no es conservadurismo. Es alineamiento con la evidencia más reciente sobre dónde los sistemas de IA realmente funcionan en biomedicina.

Decisión 2: AWS publicó (noviembre 2025) cuatro patrones canónicos para human-in-the-loop en healthcare y life sciences.

Un blog post oficial de AWS de noviembre 2025 (“Human-in-the-loop constructs for agentic workflows in healthcare and life sciences”) identifica cuatro patrones complementarios para implementar HITL en workflows agénticos. Los patrones que describen — centralizado, tool-specific, asíncrono, y real-time — mapean directamente a los human gates que el proyecto ya tiene en su arquitectura dual-method.

AWS explícitamente nombra los drivers de estos patrones: cumplimiento regulatorio (las regulaciones GxP requieren supervisión humana para operaciones sensibles), seguridad del paciente, requerimientos de auditoría, y sensibilidad de datos.

Lo que esto significa: la arquitectura de human gates del proyecto está alineada con patrones reconocidos por uno de los proveedores cloud más grandes del mundo, específicamente para el dominio (healthcare/life sciences) en el que opera el proyecto.

Decisión 3: Mantener disciplina de auditoría.

La revisión sistemática de evaluación de modelos de lenguaje (Laskar et al. 2024, mantenido por la regla porque sus conclusiones siguen vigentes) específicamente recomienda metodologías de evaluación reproducibles, confiables, y robustas. Los autores critican explícitamente la “complejidad del proceso de evaluación que ha llevado a setups variados, causando inconsistencias en findings e interpretaciones.”

Lo que esto significa: la disciplina de auditoría que el proyecto ya tiene incorporada — la práctica de nombrar explícitamente qué se prueba y qué no, qué thresholds son ambiciosos vs defensivos, qué claims se atemperan con qué findings — está exactamente en la dirección que la literatura técnica recomienda. Eso es calidad operativa difícil de adquirir y el proyecto ya la tiene incorporada como cultura.

Decisión 4: Los validation gates biológicos como capa de protección.

El proyecto separa explícitamente las pruebas del substrate (Tests 1-5) de los validation gates biológicos (Induction, Specificity, Identity, Parsimony). Los gates biológicos se miden con readouts experimentales — transcriptómica, imaging, histología — no con juicio de modelo de lenguaje.

Lo que esto significa: el proyecto tiene una capa de validación independiente del razonamiento de modelos. Aún si todas las críticas de la Parte 2 sobre el substrate fueran correctas y demoledoras, los gates biológicos siguen funcionando porque dependen de evidencia empírica directa. **Esa es probablemente la decisión arquitectónica más importante del proyecto.** Es una protección estructural contra el riesgo de razonamiento.

Lo que el proyecto puede genuinamente entregar en Phase I

A la luz de toda la evidencia (la favorable y la adversa), aquí está lo que el proyecto puede legítimamente lograr en 8 meses, sin sobre-prometer:

1. Validación biológica del POC de organogénesis. Los cuatro success gates (Induction, Specificity, Identity, Parsimony) son alcanzables independientemente del rendimiento del substrate. La biología es la biología.

2. Evidencia preliminar pero real de propiedades substrate. Los Tests 1-5 producirán datos. No al threshold ambicioso original — pero a niveles defensivos que demuestran que la dirección es viable. Mejorar 3x un sistema fundamentalmente miscalibrado en 8 meses es ambicioso; mejorarlo 1.5x es realista y publicable.

3. Una arquitectura defensible que puede operarse en producción. El stack que el proyecto está construyendo — DATA INAMOVIBLE + agentes especializados + frameworks de razonamiento + human gates estructurados — corresponde a lo que la industria reconoce como compound AI systems. Es un stack que se puede mantener, extender, y mejorar a lo largo del tiempo.

4. Una metodología documentada de auditoría continua. La práctica del proyecto de nombrar explícitamente lo que se prueba y lo que no, de tratar los thresholds como aspiracionales vs defensivos, de visitar la evidencia técnica cada seis meses — todo eso es metodología transferible. No solo entrega resultados; entrega un manual de cómo hacer este tipo de proyecto sin auto-engañ.

5. Una contribución científica posible. La validación honesta de qué propiedades del substrate son alcanzables y cuáles no, en qué horizontes y bajo qué condiciones, es por sí mismo un resultado científico publicable. No solo “construimos un sistema y funciona” — sino “caracterizamos qué partes del approach funcionan y qué partes no, con evidencia rigurosa.” Eso es lo que la literatura biomédica reconoce como contribución.

Conclusión · lo que se está construyendo merece reconocimiento

Es fácil leer un documento de stress-test largo y quedarse con la impresión de que el proyecto está en problemas. No lo está. Está en territorio difícil, pero el territorio está empíricamente accesible y otros proyectos lo están atravesando.

Tres cosas que el equipo merece reconocer explícitamente:

Primero, la decisión de empezar con biología en vez de framing puro de substrate. Muchos proyectos ambiciosos de AI en 2025 se quedan en el plano de “construyamos infraestructura de IA y veamos qué emerge.” El proyecto eligió un dominio concreto, con outcomes verificables, con partners académicos reales, y con una pregunta científica genuina. Esto convierte un proyecto especulativo en un proyecto con piso. Aún si todo lo demás falla, el POC de organogénesis es un experimento científico legítimo que vale la pena hacer.

Segundo, el reconocimiento explícito de la diferencia entre Method 1 y Method 2. Diseñar arquitectura dual desde el inicio, con human-in-the-loop como modo principal, es exactamente lo que la literatura más reciente recomienda. Esa intuición no es accidental — refleja experiencia operativa real con sistemas de IA y juicio sobre dónde realmente fallan.

Tercero, la disciplina de mantener la honestidad técnica. Este documento entero existe porque alguien preguntó “¿qué tan parado está esto?” y luego pidió que la respuesta fuera tan honesta como pudiera serlo. Esa cultura — de exponer las vulnerabilidades antes de que las exponga el adversario, de balancear ambición con realismo, de tratar los thresholds como hipótesis a refinar y no como compromisos a defender — es quizás la cualidad más rara y más valiosa del proyecto. Las arquitecturas se ajustan; los thresholds se recalibran; las decisiones técnicas se revisitan. Pero la cultura que sostiene esos ajustes — la disposición a hacerlos cuando la evidencia lo demanda — es lo que distingue a los proyectos que terminan funcionando de los que se autoengañan hasta colapsar.

El proyecto Witt × Organogenesis está apostando a un espacio difícil. La evidencia 2025+ sugiere que es un espacio donde sí se puede operar — con disciplina, con humildad técnica, con honestidad sobre lo que se sabe y lo que no se sabe. El equipo ya tiene esas tres cosas incorporadas en cómo opera. Eso es la base más sólida sobre la que se puede construir algo en este territorio.

Bibliografía consolidada

Cada referencia incluye su identificador para acceso público.

Sobre fragilidad y limitaciones del razonamiento:

- Mirzadeh, I., Alizadeh, K., Shahrokhi, H., Tuzel, O., Bengio, S., & Farajtabar, M. (2024). *GSM-Symbolic: Understanding the Limitations of Mathematical Reasoning in Large Language Models*. arXiv:2410.05229. (Mantenido por la regla — conclusión negativa no revertida.)
- Heyman et al., mayo 2025. Constraint satisfaction failures in graph coloring problems.
- Roh et al., junio 2025. Prompt perturbation effects on reasoning.
- Khalid et al., marzo 2025. Disjunctive reasoning failures.
- Wang & Sun, 2025. Proactive interference in LLM working memory.
- Magraner et al., agosto 2025. *Knowledge-Reasoning Dissociation: Fundamental Limitations of LLMs in Clinical Natural Language Inference*. arXiv:2508.10777.

Sobre fidelidad de las cadenas de pensamiento:

- Anthropic Research Team, abril 2025. Faithfulness study on Claude 3.7 Sonnet and DeepSeek R1. Disponible en la página de research de Anthropic.
- FaithCoT-Bench Authors, 2025. *FaithCoT-Bench: Benchmarking Instance-Level Faithfulness of Chain-of-Thought Reasoning*. arXiv:2510.04040.
- Concept Walk Authors, octubre 2025. *Mapping Faithful Reasoning in Language Models*. arXiv:2510.22362.

Sobre calibración:

- Vega, T., et al., febrero 2025. *A Study of Calibration as a Measurement of Trustworthiness of Large Language Models in Biomedical Research*. bioRxiv. doi:10.1101/2025.02.11.637373.

Sobre escalamiento en tiempo de inferencia:

- Su, J., et al., mayo 2025. *Don't Overthink It. Preferring Shorter Thinking Chains for Improved LLM Reasoning*. arXiv:2505.17813.

- Agarwal, A., et al., diciembre 2025. *The Art of Scaling Test-Time Compute for Large Language Models*. arXiv:2512.02008.

Sobre el cambio de fase de 2025:

- Guo, D., et al., enero 2025. *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning*. arXiv:2501.12948. Versión final publicada en *Nature*, septiembre 2025: doi:10.1038/s41586-025-09422-z.
- Aichberger, L., et al., marzo 2025. *Reasoning Beyond Limits: Advances and Open Problems for LLMs*. arXiv:2503.22732.

Sobre Retrieval-Augmented Generation:

- Brown, A., Roman, M., & Devereux, B., agosto 2025. *A Systematic Literature Review of Retrieval-Augmented Generation: Techniques, Metrics, and Challenges*. arXiv:2508.06401.
- Wright et al., 2025. BioThings Explorer-Retrieval-Augmented Generation (BTE-RAG). PubMed Central PMC12888809.

Sobre sistemas multi-agente y validación experimental en biología (referencias de la Parte 4):

- Boiko, D. A., et al., julio 2025. *Agentic AI Integrated with Scientific Knowledge: Laboratory Validation in Systems Biology*. bioRxiv. doi:10.1101/2025.06.24.661378. Sistema multi-agente con validación experimental en levadura.
- BioLab authors, septiembre 2025. *BioLab: End-to-End Autonomous Life Sciences Research with Multi-Agents System Integrating Biological Foundation Models*. bioRxiv. doi:10.1101/2025.09.03.674085. Sistema multi-agente con closed-loop wet-lab.
- Trehan, D., & Chopra, P., enero 2026. *Why LLMs Aren't Scientists Yet: Lessons from Four Autonomous Research Attempts*. arXiv:2601.03315. Análisis honesto de los modos de fallo de pipelines completamente autónomos.
- "From Task Executors to Research Partners," diciembre 2025. arXiv:2512.04854. Survey sobre AI co-pilots en investigación biomédica. Incluye referencia a Recursion Pharmaceuticals operando 2.2 millones de experimentos por semana con AI guiada.

Sobre human-in-the-loop AI en biomedicina (referencias de la Parte 4):

- Human-in-the-Loop AI Systematic Review, marzo 2026. mdpi.com/1099-4300/28/4/377. Revisión sistemática de HITL como dirección clave para aplicaciones high-stakes.
- "Human in the loop artificial intelligence in healthcare," febrero 2026. ScienceDirect, S1386505626001024. Síntesis de evidencia 2018-2025 sobre HITL en healthcare.
- AWS Machine Learning Blog, noviembre 2025. *Human-in-the-loop constructs for agentic workflows in healthcare and life sciences*. aws.amazon.com/blogs/machine-learning/human-in-the-loop-constructs-for-agentic-workflows-in-healthcare-and-life-sciences/. Cuatro patrones canónicos.

Sobre el ecosistema industrial (referencias de la Parte 4):

- Bessemer Venture Partners, agosto 2025. *The State of AI 2025*. bvp.com/atlas/the-state-of-ai-2025. Mapa del stack de infraestructura emergente.
- Menlo Ventures, diciembre 2025. *State of Generative AI in the Enterprise 2025*. menlovc.com/perspective/2025-the-state-of-generative-ai-in-the-enterprise/. Inversión empresarial en infraestructura de IA.
- Judgment Labs, fundada 2025. judgmentlabs.ai. Empresa construyendo Agent Behavior Monitoring infrastructure. Framework open-source: Judgeval.

Recursos vivos para seguir el campo:

- Awesome-LLM-Reasoning — github.com/atfortes/Awesome-LLM-Reasoning. Catálogo curado y actualizado de papers sobre razonamiento.
- arXiv (sección cs.CL — Computational Linguistics) — arxiv.org/list/cs.CL/recent. Donde se publican casi todos los papers sobre estos modelos.

Una nota final sobre cómo usar este documento

Este documento es una stress-test acompañada de un balance honesto. Su propósito es exponer dónde el proyecto es vulnerable a la luz de evidencia técnica (Partes 1-3) y dónde el approach está respaldado por la literatura y por precedentes industriales (Parte 4). No es un documento estratégico. Las decisiones operativas, las prioridades de implementación, y las trade-offs entre ambición y conservadurismo son decisiones del equipo, no de este documento.

Cuatro formas en las que este documento se vuelve útil:

1. **Como input para revisar el scope doc.** Las recalibraciones de thresholds (Test 3, Test 4, Test 5) y los ajustes interpretativos (campo `framework_applied`) producen una versión más defendible del scope.
2. **Como base para discusión técnica con cualquier asesor o colaborador externo.** Los argumentos técnicos están aquí. Las objeciones a esperar están aquí. Las defensas también están aquí.

3. **Como punto de partida para las primeras iteraciones operativas.** Empezar con RAG simple, aplicar Self-Consistency desde el día 1, tratar al auditor como compuesto en vez de monolítico — son decisiones que se toman antes de escribir código.
4. **Como respaldo cuando alguien cuestione si el proyecto es viable.** La Parte 4 documenta empresas, papers, y precedentes que confirman que el espacio del proyecto es real. Si alguien pregunta “¿por qué creen que esto se puede hacer?”, la respuesta está ahí con citas verificables.

El documento debería revisitarse cada 6 meses. La evidencia 2025+ ya está cambiando el panorama; lo que hoy es “no resuelto” puede haber cambiado en cualquier dirección antes de Phase II. Lo que hoy es precedente sólido puede haberse expandido o ajustado. Mantener este análisis vivo es parte de la disciplina de auditoría que ya forma parte del proyecto.

— Fin del documento —